NLP项目

RNN、LSTM

课程内容

- 递归神经网络(RNN)
  - 什么是递归神经网络
  - 应用场景
  - 层次结构
  - RNN描述
- LSTM
- GRU

什么是递归神经网络

- 为什么有BP神经网络、CNN，还需要RNN?
  - BP神经网络和CNN的输入输出都是互相独立的；但是实际应用中有些场景输出内容和之前的内容是有关联的。
  - RNN引入“记忆”的概念；递归指其每一个元素都执行相同的任务，但是输出依赖于输入和“记忆”。

什么是递归神经网络

- 我们已经学习了前馈网络的两种结构——BP神经网络和卷积神经网络，这两种结构有一个特点，就是假设输入是一个独立的没有上下文联系的单位，比如输入是一张图片，网络识别是狗还是猫。但是对于一些有明显的上下文特征的序列化输入，比如预测视频中下一帧的播放内容，那么很明显这样的输出必须依赖以前的输入， 也就是说网络必须拥有一定的”记忆能力”。为了赋予网络这样的记忆力，一种特殊结构的神经网络——递归神经网络(Recurrent Neural Network)便应运而生了。

递归神经网络RNN-应用场景

- 自然语言处理(NLP)
  - 语言模型与文本生成
- 机器翻译
- 语音识别
- 图像描述生成
- 文本相似度计算等

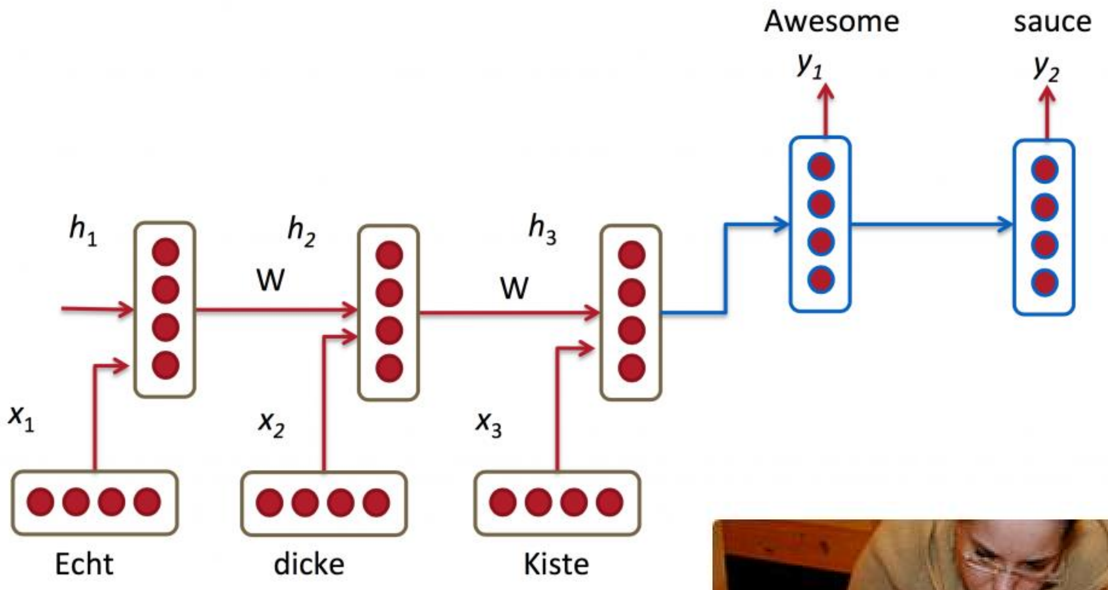

"man in black shirt is playing guitar."

"two young girls are playing with lego toy."

神经网络之结构

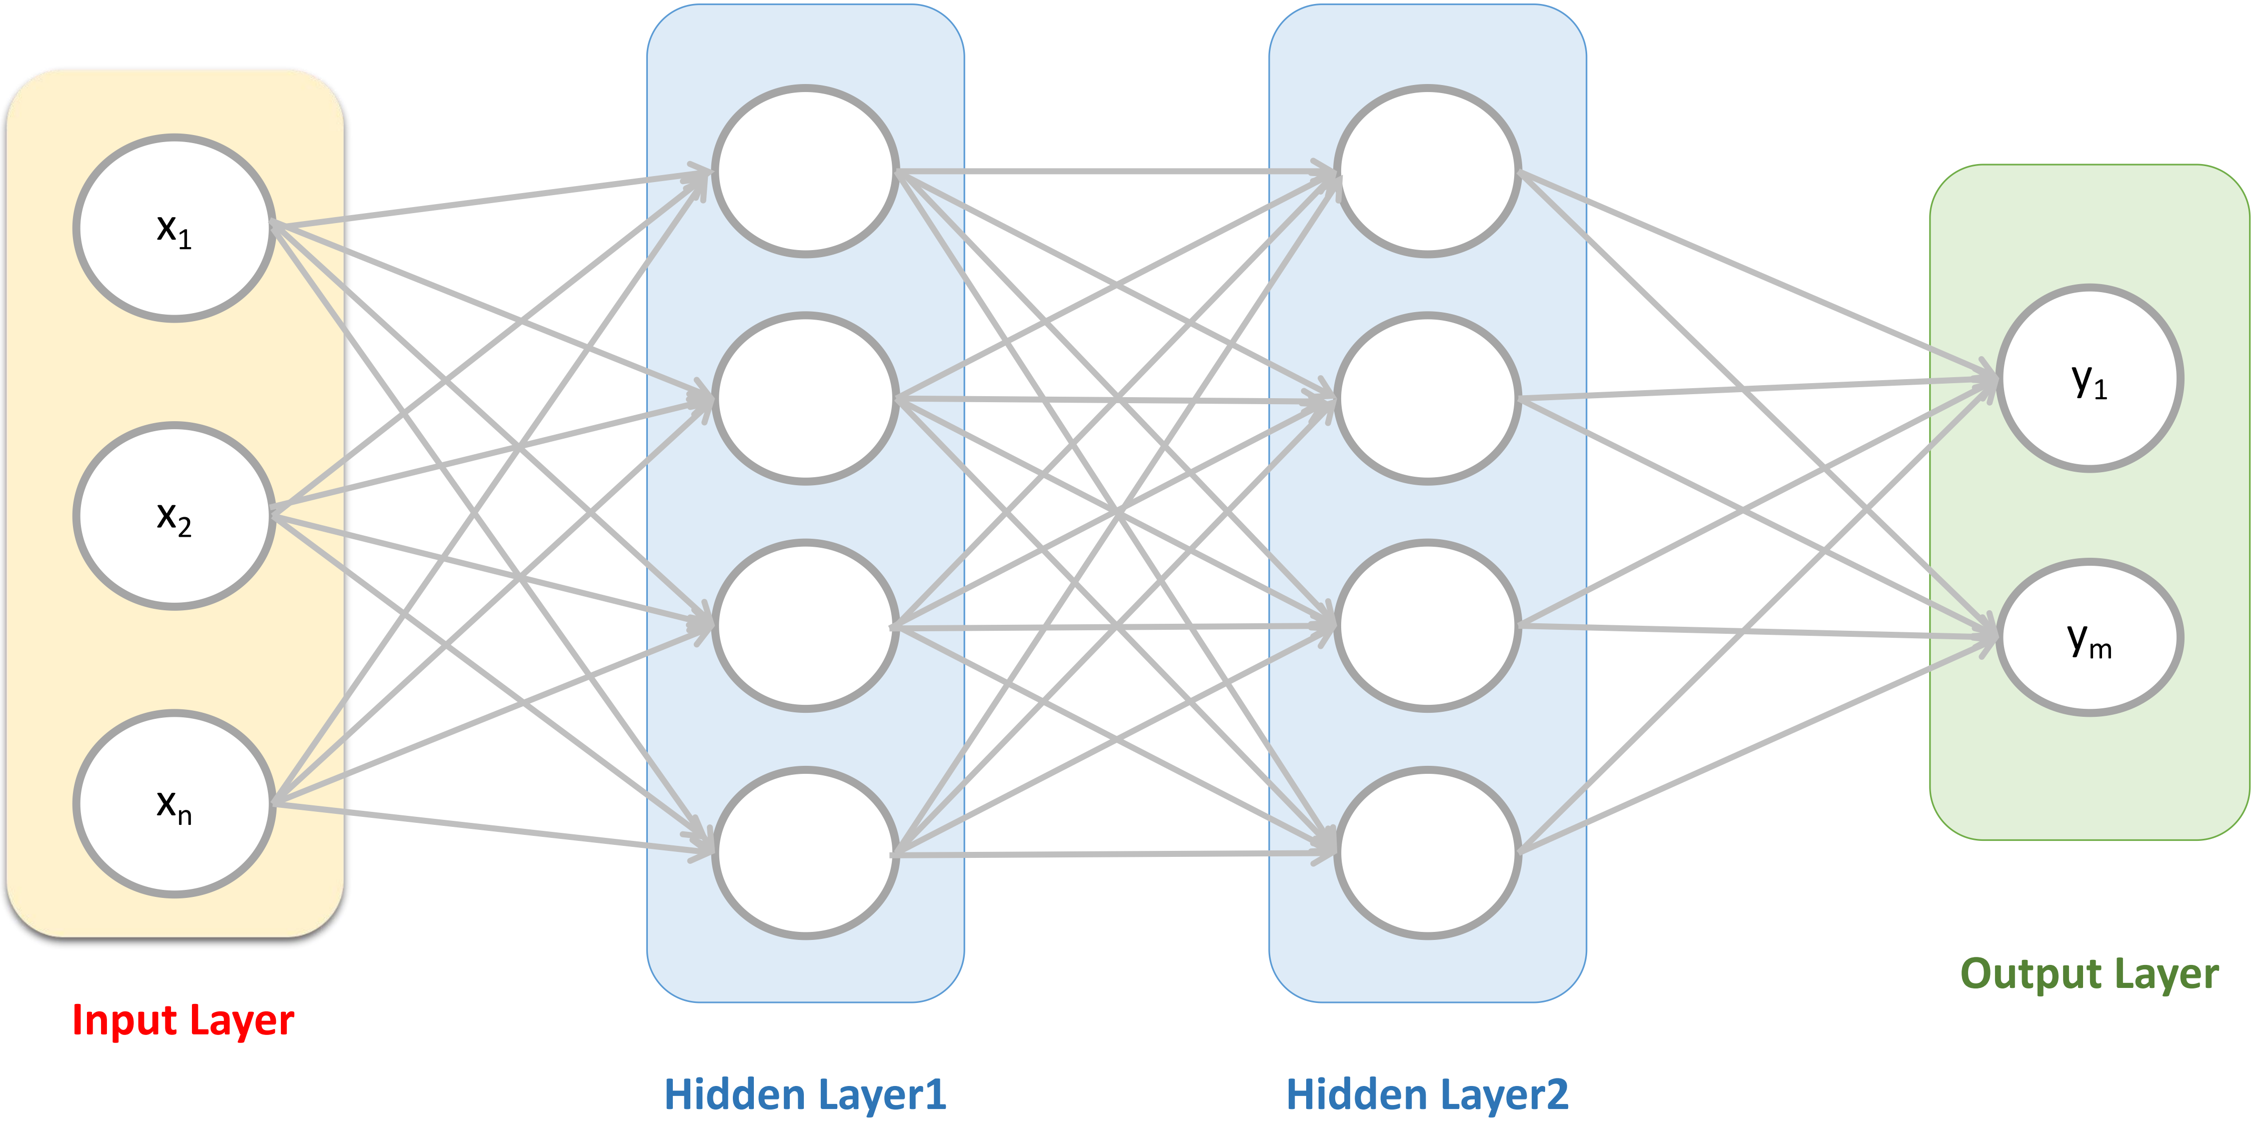

x_1
x_2
x_n
y_1
y_m
Input Layer
Hidden Layer1
Hidden Layer2
Output Layer

RNN-结构

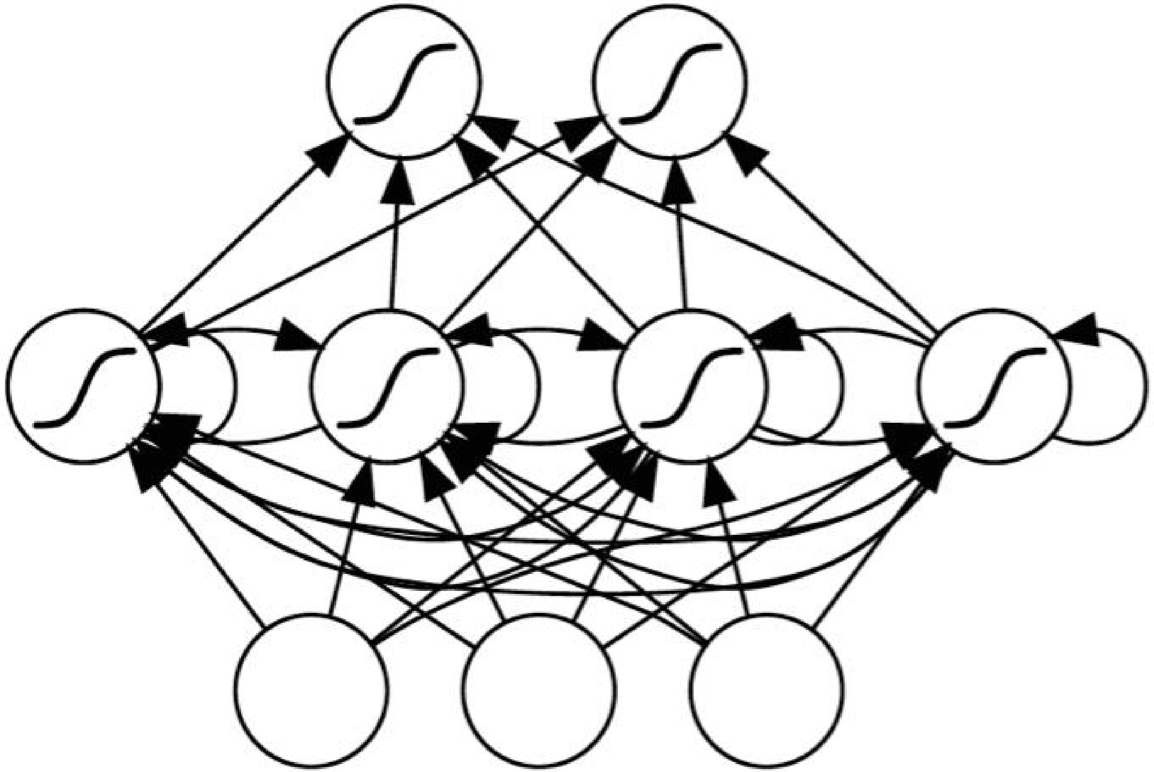

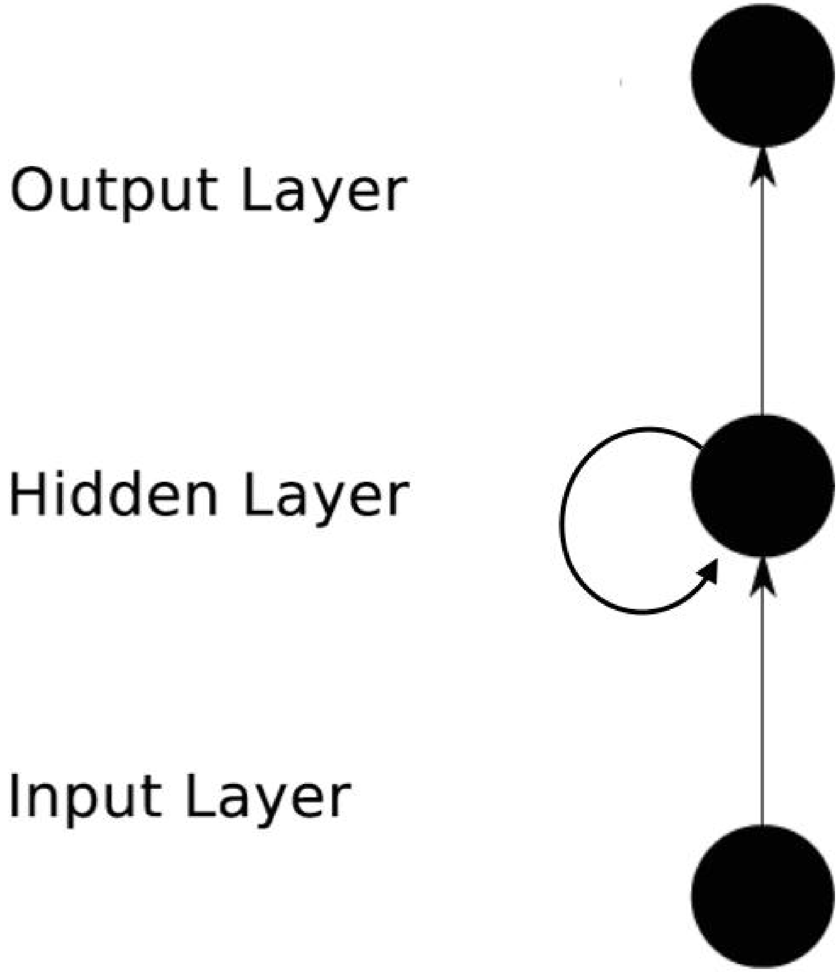

RNN-结构

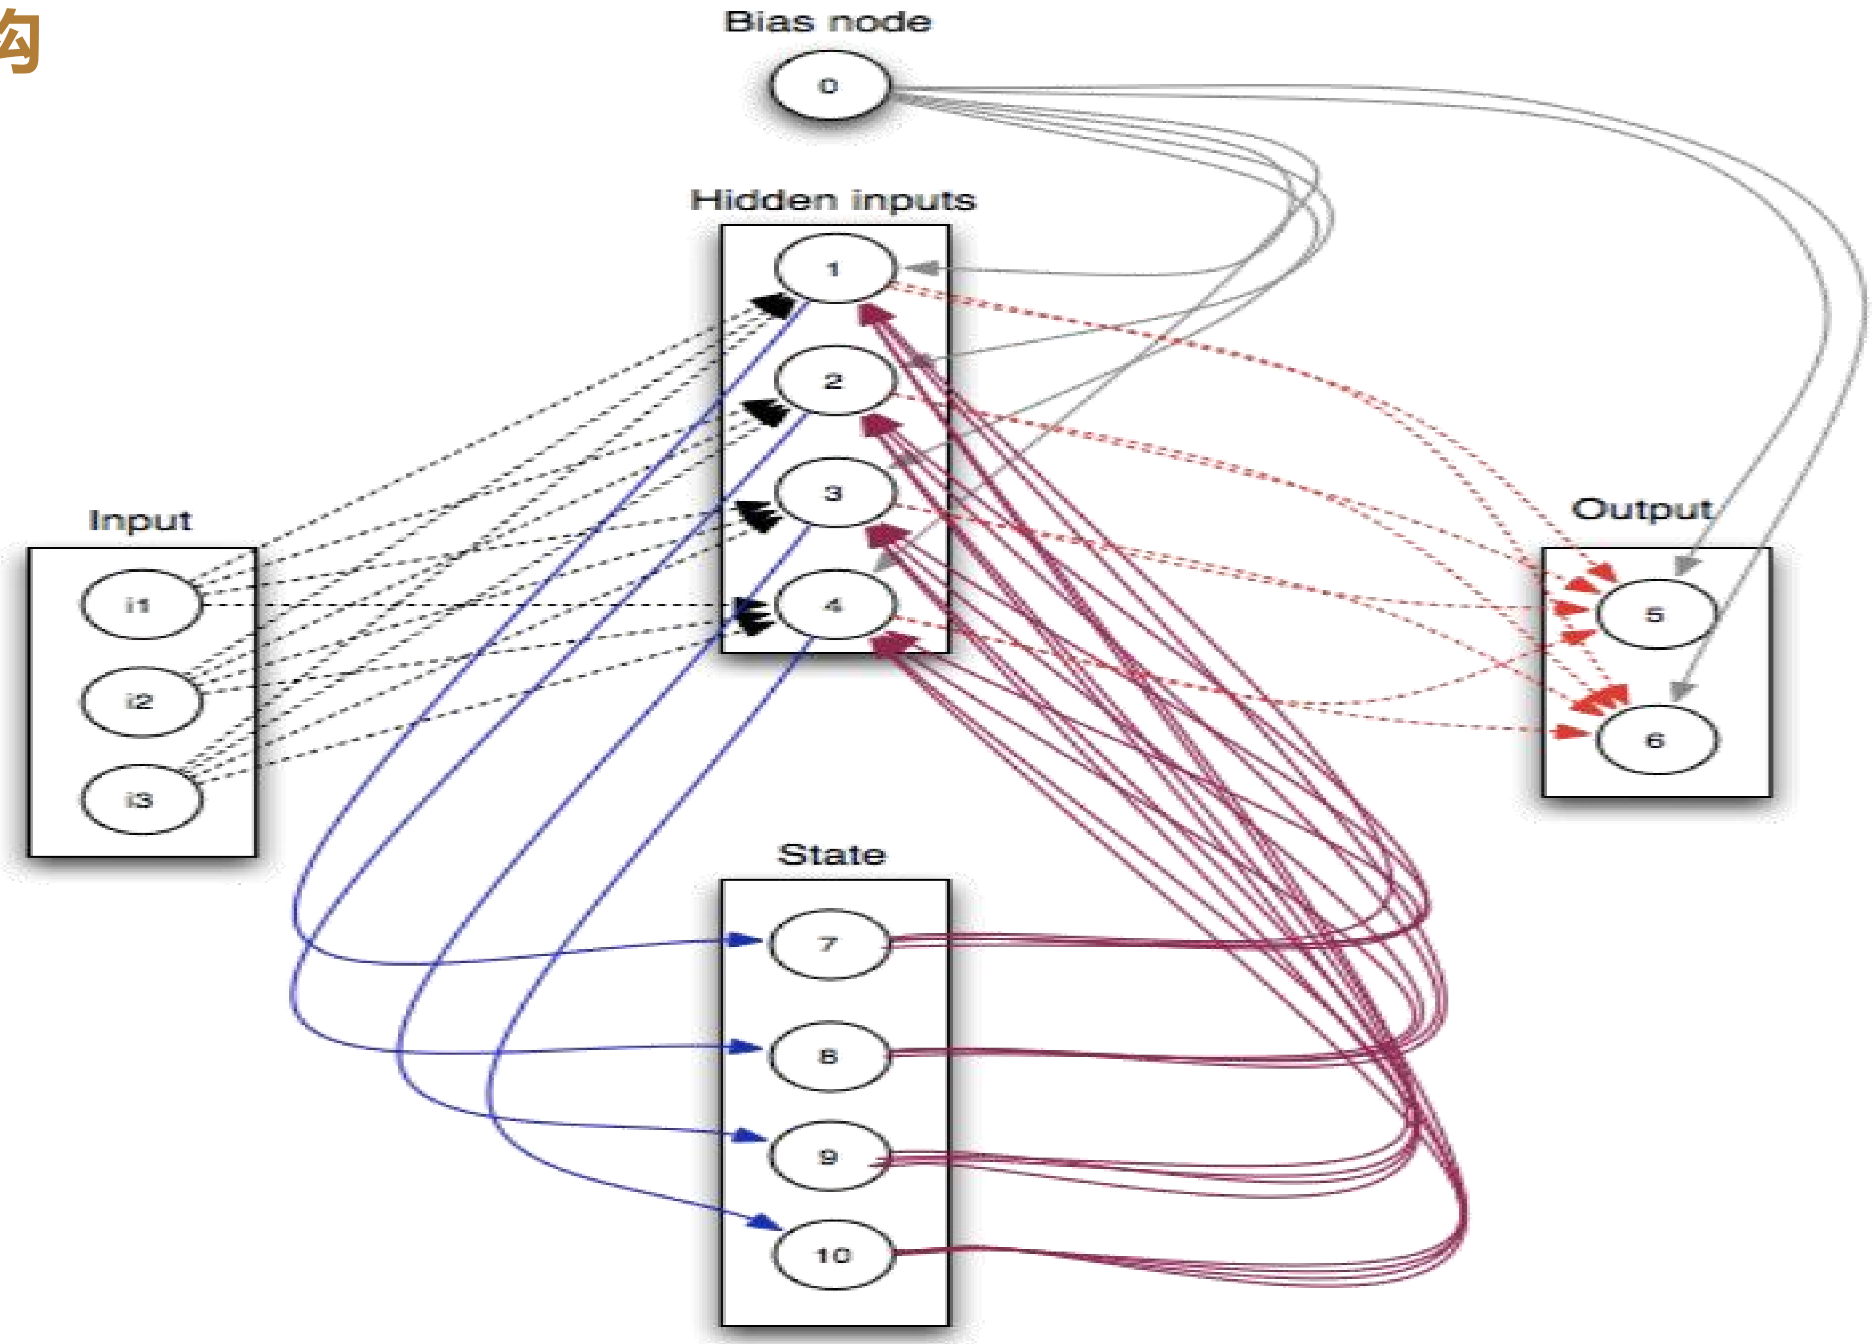

Bias node
0
Hidden inputs
1
2
3
4
Input
i1
i2
i3
Output
5
6
State
7
8
9
10

RNN-结构

- 网络某一时刻的输入x_t，和之前介绍的bp神经网络的输入一样，x_t是一个n维向量，不同的是递归网络的输入将是一整个序列，也就是$x=[x_1,...,x_{t-1},x_t,x_{t+1},...x_T]$，对于语言模型，每一个$x_t$将代表一个词向量，一整个序列就代表一句话/一个文本。
- h_t或者S_t代表时刻t的隐藏状态/状态信息/记忆信息/RNN的输出
- o_t代表时刻t的输出 --> 和RNN没有关系
- 输入层到隐藏层之间的权重由U表示，它将我们的原始输入进行抽象作为隐藏层的输入
- 隐藏层到隐藏层的权重W，它是网络的记忆控制者，负责调度记忆。
- 隐藏层到输出层的权重V，从隐藏层学习到的表示将通过它再一次抽象，并作为最终输出。NOTE: **权重V并不属于循环神经网络。**

RNN-结构

- 将序列按时间展开就可以得到RNN的结构
  - X_t是时间t处的输入
  - S_t是时间t处的“记忆”，$S_t=f(UX_t+WS_{t-1})$，f可以是非线性转换函数，比如tanh等
  - O_t是时间t处的输出，比如是预测下一个词的话，可能是sigmoid/softmax输出的属于每个候选词的概率，$O_t=softmax(VS_t)$

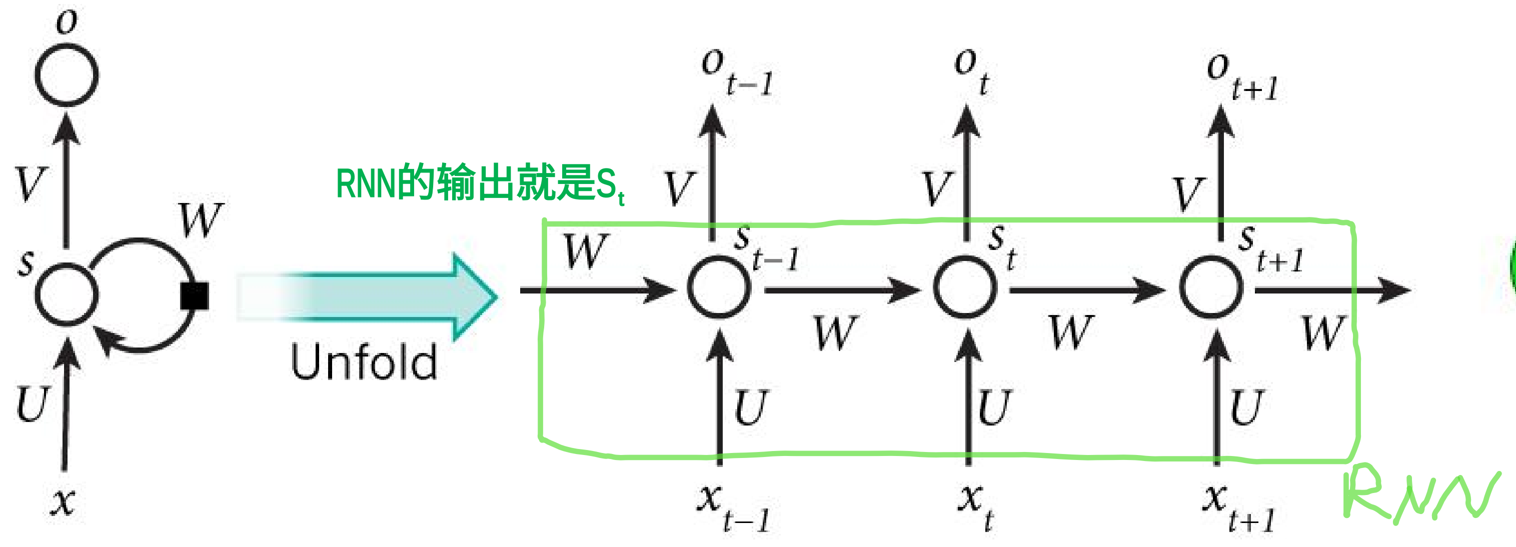

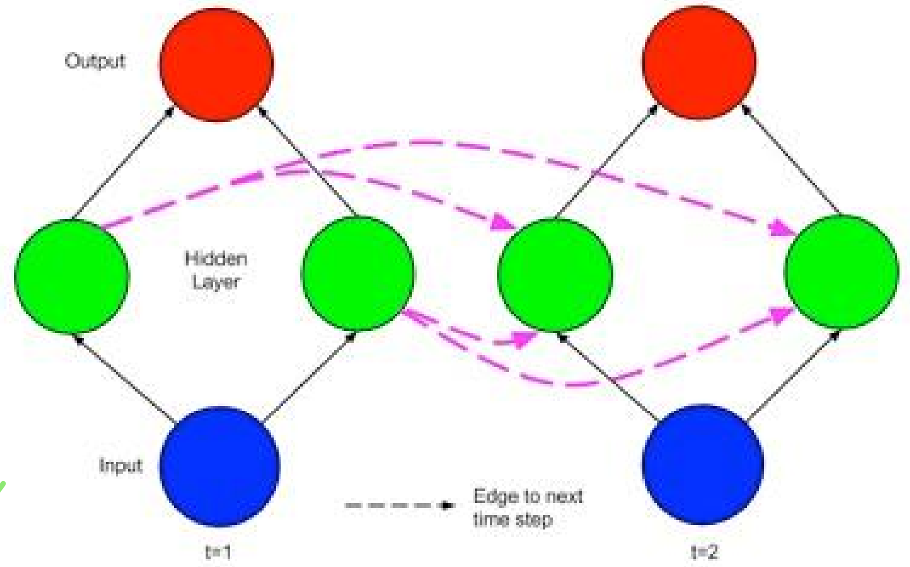

RNN-结构

- 按照一定的时间序列规定好计算顺序，于是实际上我们会将这样带环的结构展开成一个序列网络，也就是上图右侧被“unfold”之后的结构。

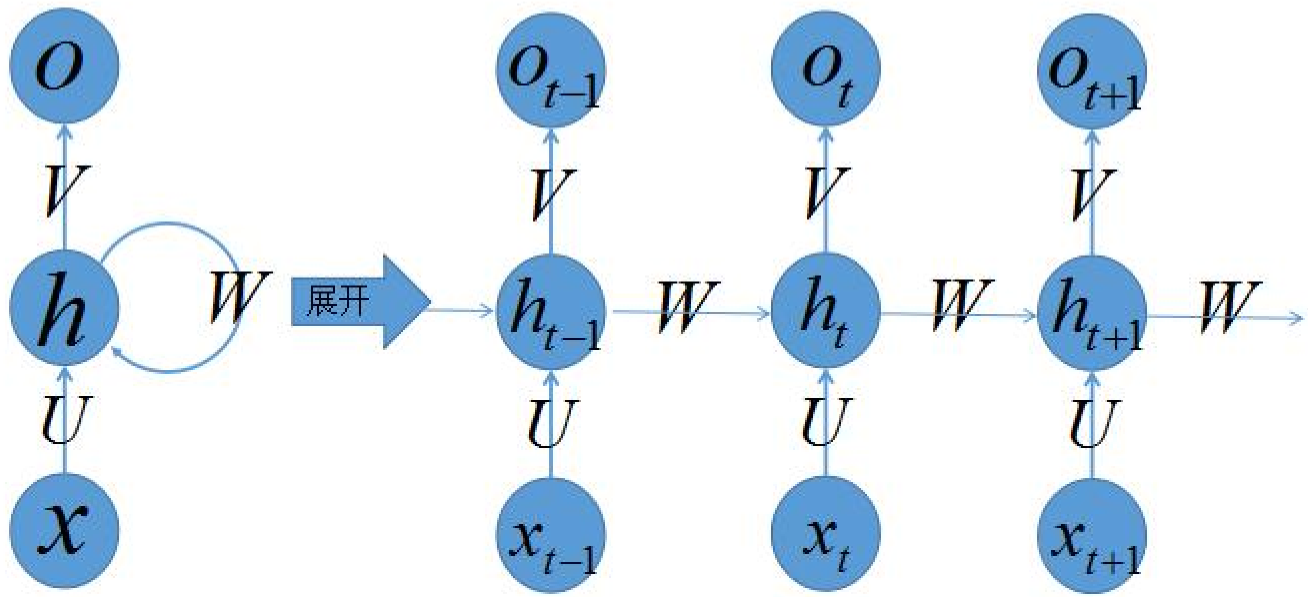

RNN正向传播阶段

- 在t=1的时刻，U,V,W都被随机初始化好，h0通常初始化为0，然后进行如下计算：

$$
\begin{aligned}
s_1 &= Ux_1 + Wh_0 \\
h_1 &= f(s_1) \\
o_1 &= g(Vh_1)
\end{aligned}
$$

- 时间就向前推进，此时的状态h_1作为时刻1的记忆状态将参与下一次的预测活动，也就是：

$$
\begin{aligned}
s_2 &= Ux_2 + Wh_1 \\
h_2 &= f(s_2) \\
o_2 &= g(Vh_2)
\end{aligned}
$$

RNN正向传播阶段

- 以此类推，可得

$$
\begin{aligned}
s_t &= Ux_t + Wh_{t-1} \\
h_t &= f(Ux_t + Wh_{t-1}) \\
o_t &= g(Vh_t)
\end{aligned}
$$

RNN

- 其中f可以是tanh,relu,sigmoid等激活函数，g通常是softmax也可以是其他。
  值得注意的是，我们说递归神经网络拥有记忆能力，而这种能力就是通过W将以往的输入状态进行总结，而作为下次输入的辅助。可以这样理解隐藏状态：**h=f(当前输入+过去记忆总结)**

RNN反向传播阶段

- bp神经网络用到的误差反向传播方法将输出层的误差总和，对各个权重的梯度∇U,∇V,∇W，求偏导数，然后利用梯度下降法更新各个权重。
- 对于每一时刻t的RNN网络，网络的输出o_t都会产生一定误差e_t，误差的损失函数，可以是交叉熵也可以是平方误差等等。那么总的误差为$E=\sum_t e_t$，我们的目标就是要求取

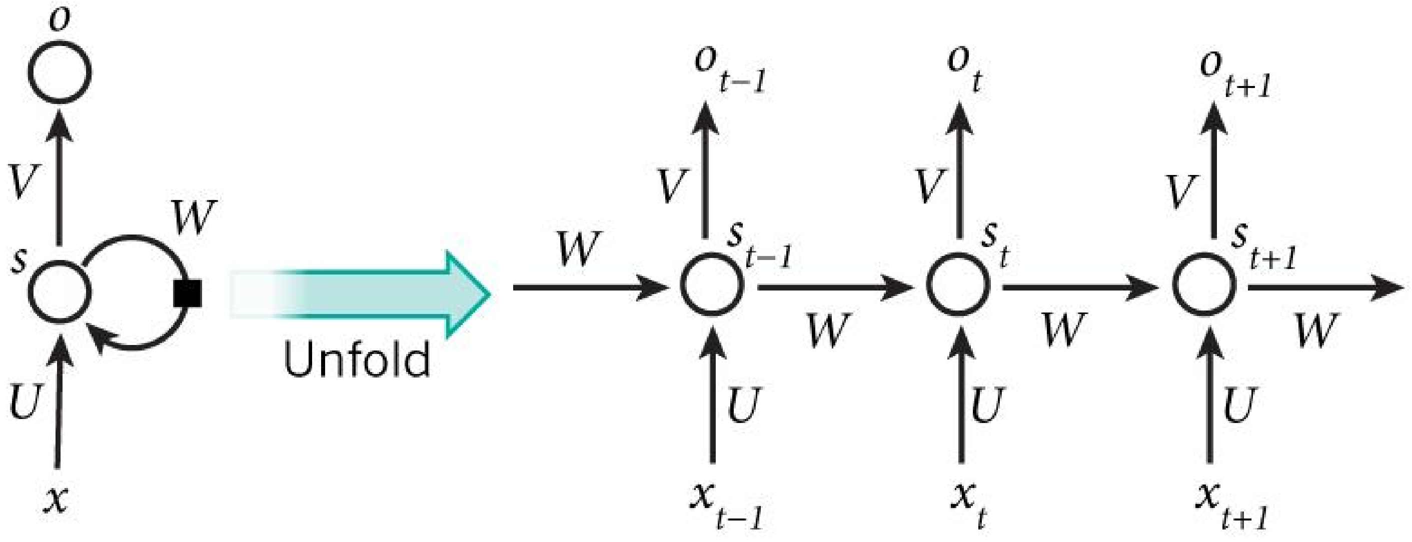

$$\nabla U = \frac{\partial E}{\partial U} = \sum_t \frac{\partial e_t}{\partial U}$$

$$\nabla V = \frac{\partial E}{\partial V} = \sum_t \frac{\partial e_t}{\partial V}$$

$$\nabla W = \frac{\partial E}{\partial W} = \sum_t \frac{\partial e_t}{\partial W}$$

RNN反向传播阶段

- 对于输出$o_t=g(Vs_t)$,对于任意损失函数，求取▽V将是简单的，我们可以直接求取每个时刻的$\partial e_t / \partial V$，由于它不存在和之前的状态依赖，可以直接求导取得，然后简单地求和即可。对于▽W,▽U的计算不能直接求导，因此需要用链式求导法则。

RNN反向传播阶段

- 举个详细的例子计算W梯度的例子：

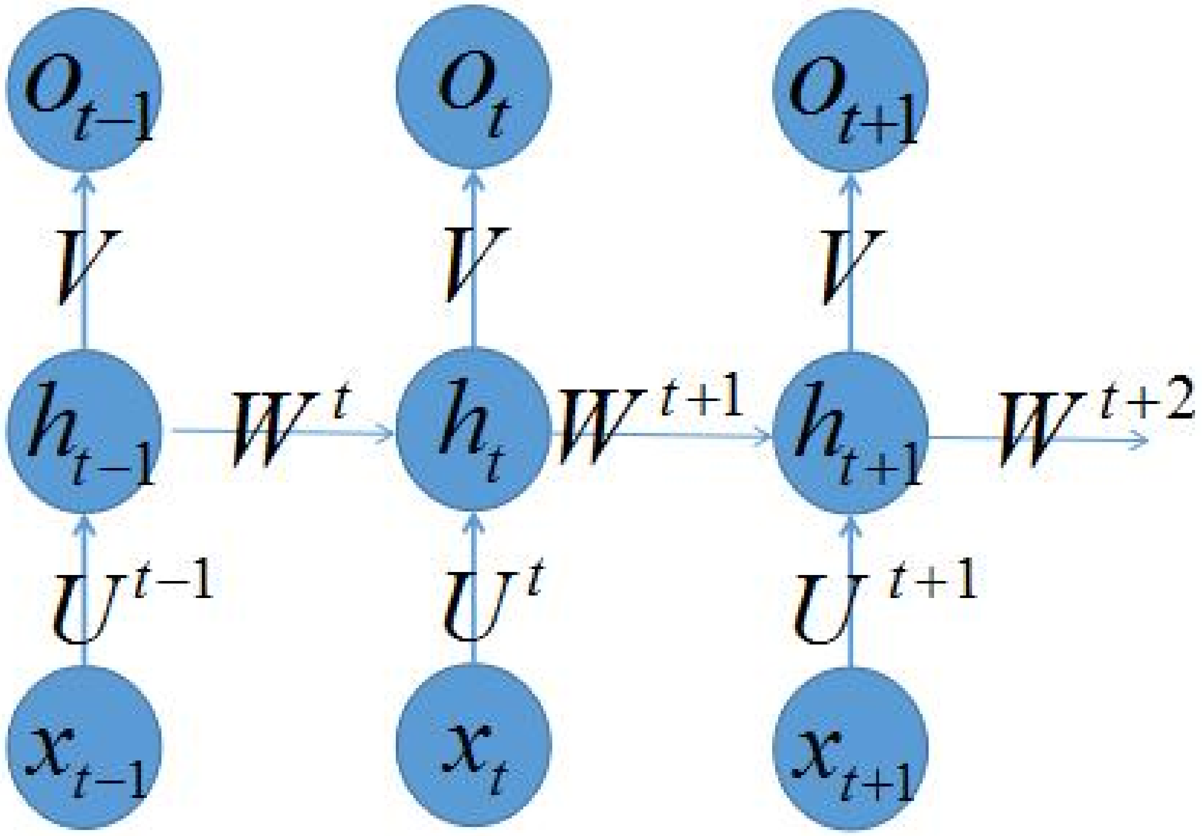

RNN反向传播阶段

- 举个对于时刻t+1产生的误差e_{t+1}，我们想计算它对于$W^1,W^2,....,W^t$，W^{t+1}的梯度，可以如下计算

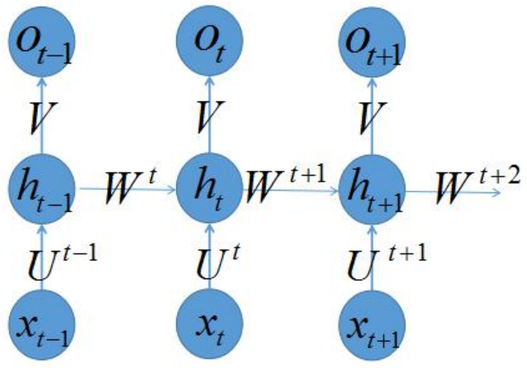

$$\frac{\partial e_{t+1}}{\partial W^{t+1}} = \frac{\partial e_{t+1}}{\partial h^{t+1}} \frac{\partial h_{t+1}}{\partial W^{t+1}}$$

$$\frac{\partial e_{t+1}}{\partial W^{t}} = \frac{\partial e_{t+1}}{\partial h^{t+1}} \frac{\partial h_{t+1}}{\partial h^{t}} \frac{\partial h_{t}}{\partial W^{t}}$$

$$\frac{\partial e_{t+1}}{\partial W^{t-1}} = \frac{\partial e_{t+1}}{\partial h^{t+1}} \frac{\partial h_{t+1}}{\partial h^{t}} \frac{\partial h_{t}}{\partial h^{t-1}} \frac{\partial h_{t-1}}{\partial W^{t-1}}$$

......

- 反复运用链式法则，我们可以求出每一个$\nabla W_1,\nabla W_2,....,\nabla W_t$，$\nabla W_{t+1}$，在不同时刻都是共享同样的参数，这样可以大大减少训练参数，和CNN的共享权重类似。对于共享参数的RNN，我们只需将上述的一系列式子抹去标签并求和，就可以得到：

RNN反向传播阶段

- 推导出来的公式为： $$\frac{\partial e_t}{\partial W} = \sum_{1\le k\le t} \frac{\partial e_t}{\partial h^t} \prod_{k<i\le t} \frac{\partial h_i}{\partial h^{i-1}} \frac{\partial^+ h_k}{\partial W}$$
- 其中 $\frac{\partial^+ h_k}{\partial W}$ 表示不利用链式法则直接求导，也就是假如对于函数f(h(x))，对其直接求导结果如下：∂f(h(x))/∂x=f′(h(x))，也就是求导函数可以写成x的表达式，也就是将h(x)看成常数了。

在Yoshua Bengio 论文中（http://proceedings.mlr.press/v28/pascanu13.pdf）证明了 $\|\prod_{k<i\le t} \frac{\partial h_i}{\partial h^{i-1}}\| \le \eta^{t-k}$ ，从而说明了这是梯度求导的一部分环节是一个指数模型，当η<1时，就会出现 $\boxed{\text{“}\textbf{梯度消失}\text{”}}$ 问题，而当η>1时，“**梯度爆炸**”也就产生了。

单个时刻

RNN反向传播阶段

- 为了克服梯度消失的问题，LSTM和GRU模型便后续被推出了，为什么LSTM和GRU可以克服梯度消失问题呢？由于它们都有特殊的方式存储”记忆”，那么以前梯度比较大的”记忆”不会像简单的RNN一样马上被抹除，因此可以一定程度上克服梯度消失问题。（问题描述：**在普通RNN中对于长序列而言，很早之前时刻输入的信息，对于当前时刻是不会产生影响的 --- 长序列信息丢失的问题 --> 长时依赖问题**）
- 另一个简单的技巧可以用来克服梯度爆炸的问题就是gradient clipping，也就是当你计算的梯度超过阈值c的或者小于阈值−c时候，便把此时的梯度设置成c或−c。

RNN反向传播阶段

- 下图所示是RNN的误差平面，可以看到RNN的误差平面要么非常陡峭，要么非常平坦，如果不采取任何措施，当你的参数在某一次更新之后，刚好碰到陡峭的地方，此时梯度变得非常大，那么你的参数更新也会非常大，很容易导致震荡问题。而如果你采取了gradient clipping这个技巧，那么即使你不幸碰到陡峭的地方，梯度也不会爆炸，因为梯度被限制在某个阈值c。

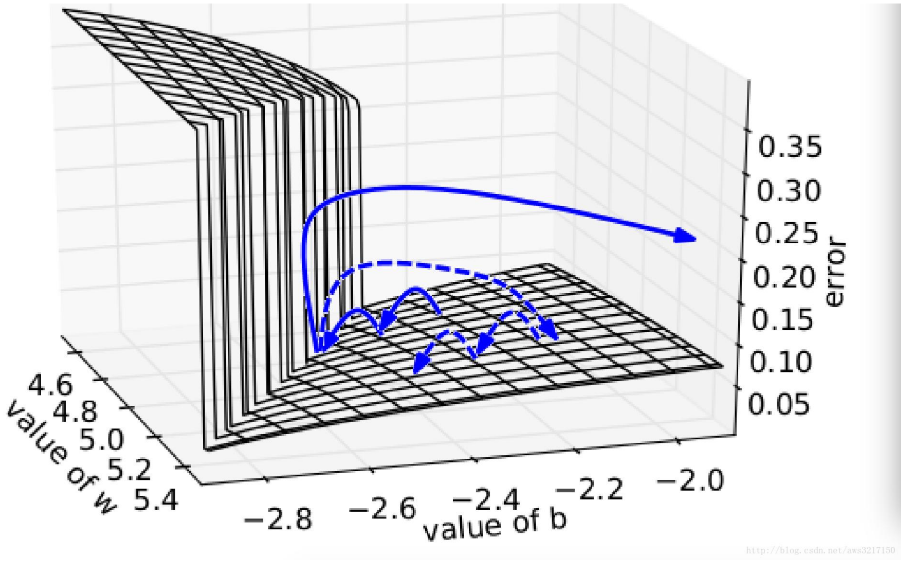

Bidirectional RNN-双向RNN

- Bidirectional RNN(双向RNN)假设当前t的输出不仅仅和之前的序列有关，并且还与之后的序列有关，例如：预测一个语句中缺失的词语那么需要根据上下文进行预测；Bidirectional RNN是一个相对简单的RNNs，由两个RNNs上下叠加在一起组成。输出由这两个RNNs的隐藏层的状态决定。

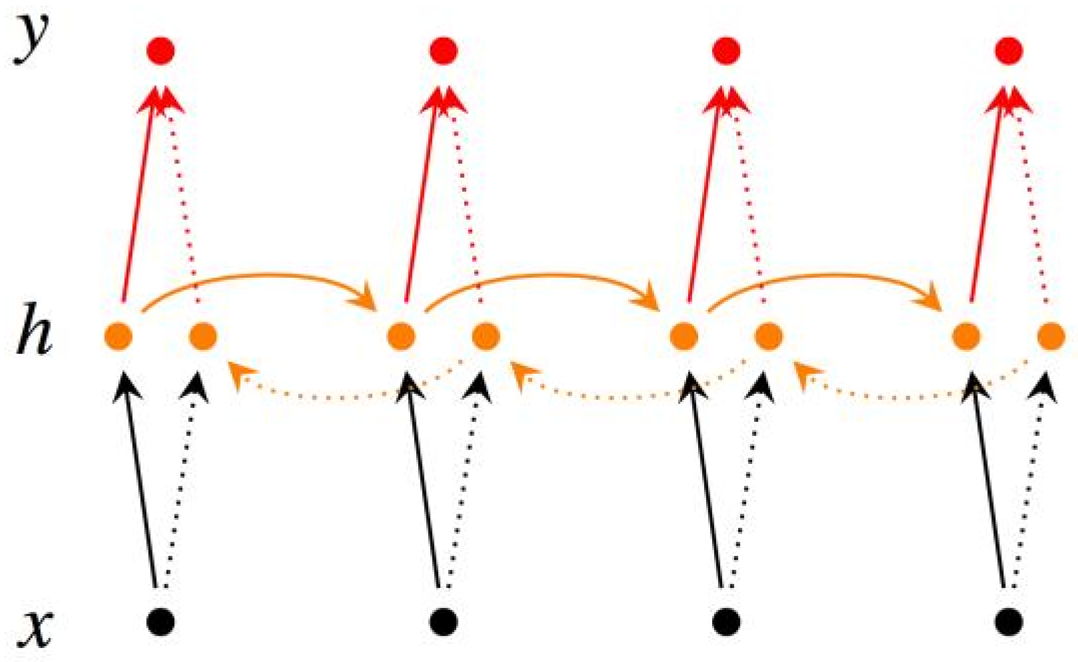

$$\overrightarrow{h}_t = f(\overrightarrow{W}x_t + \overrightarrow{V}\overrightarrow{h}_{t-1} + \overrightarrow{b})$$

$$\overleftarrow{h}_t = f(\overleftarrow{W}x_t + \overleftarrow{V}\overleftarrow{h}_{t+1} + \overleftarrow{b})$$

双向
RNN

$$y_t = g(U[\overrightarrow{h}_t;\overleftarrow{h}_t]+c)$$

Bidirectional RNN-双向RNN

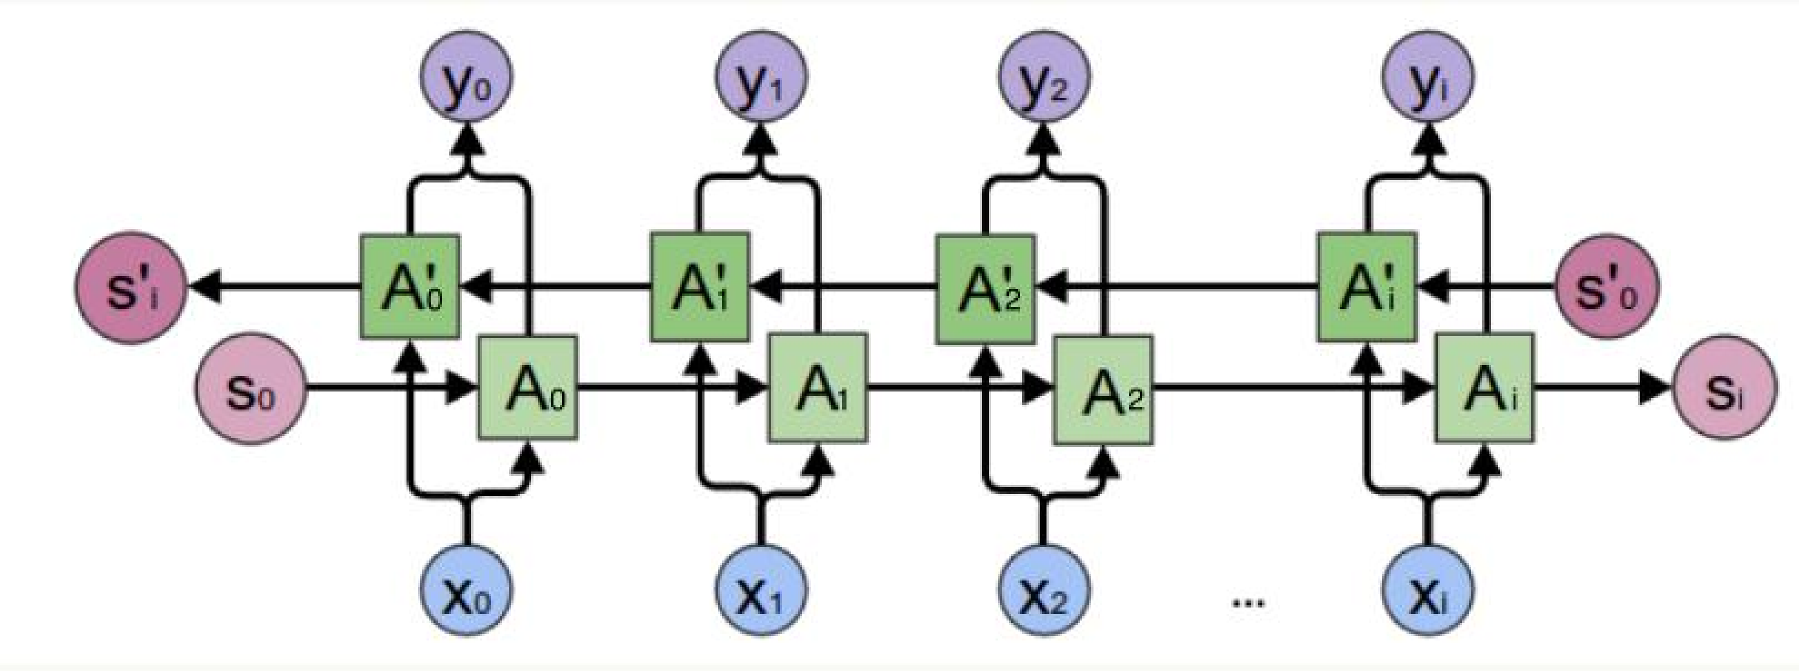

Deep(Bidirectional) RNN-深度双向RNN

- Deep Bidirectional RNN(深度双向RNN)类似Bidirectional RNN，区别在于每个每一步的输入有多层网络，这样的话该网络便具有更加强大的表达能力和学习能力，但是复杂性也提高了，同时需要训练更多的数据。

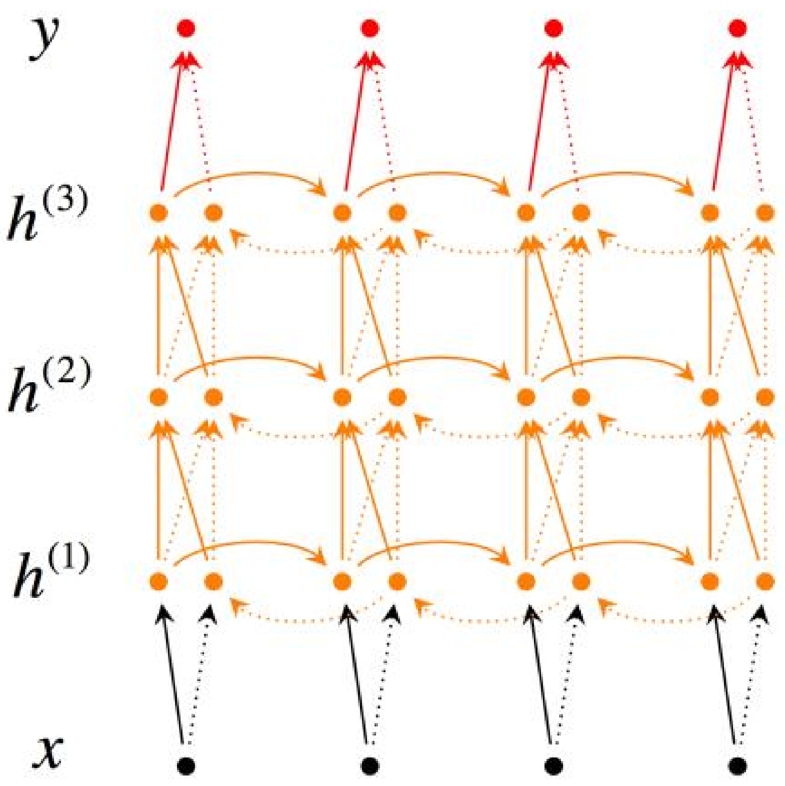

$$\overrightarrow{h}_t^{(i)} = f(\overrightarrow{W}^{(i)} h_t^{(i-1)} + \overrightarrow{V}^{(i)} \overrightarrow{h}_{t-1}^{(i)} + \overrightarrow{b}^{(i)})$$

$$\overleftarrow{h}_t^{(i)} = f(\overleftarrow{W}^{(i)} h_t^{(i-1)} + \overleftarrow{V}^{(i)} \overleftarrow{h}_{t+1}^{(i)} + \overleftarrow{b}^{(i)})$$

$$y_t = g(U[\overrightarrow{h}_t^{(L)};\overleftarrow{h}_t^{(L)}]+c)$$

循环神经网络RNN-BPTT

- RNN的训练和CNN/ANN训练一样，同样适用BP算法误差反向传播算法。区别在于：RNN中的参数U\V\W是共享的，并且在随机梯度下降算法中，每一步的输出不仅仅依赖当前步的网络，并且还需要前若干步网络的状态，那么这种BP改版的算法叫做**Backpropagation Through Time**(**BPTT**)；BPTT算法和BP算法一样，在多层(多个输入时刻)训练过程中(**长时依赖**<即当前的输出和前面很长的一段序列有关，一般超过10步>)，可能产生梯度消失和梯度爆炸的问题。
- BPTT和BP算法思路一样，都是求偏导，区别在于需要考虑时间对step的影响

LSTM

- 在RNN计算中，介绍到对于长期/**长时依赖**的问题，没法进行解决，可能产生梯度消失和梯度爆炸的问题；LSTM特别适合解决这类需要长时间依赖的问题。
- LSTM是RNN的一种变种，大体结构一致，区别在于：
  - LSTM的“记忆细胞”是改造过的
  - 该记录的信息会一直传递，不该记录的信息会被截断掉(由参数决定，也就是模型反向传播进行更新决定)

LSTM

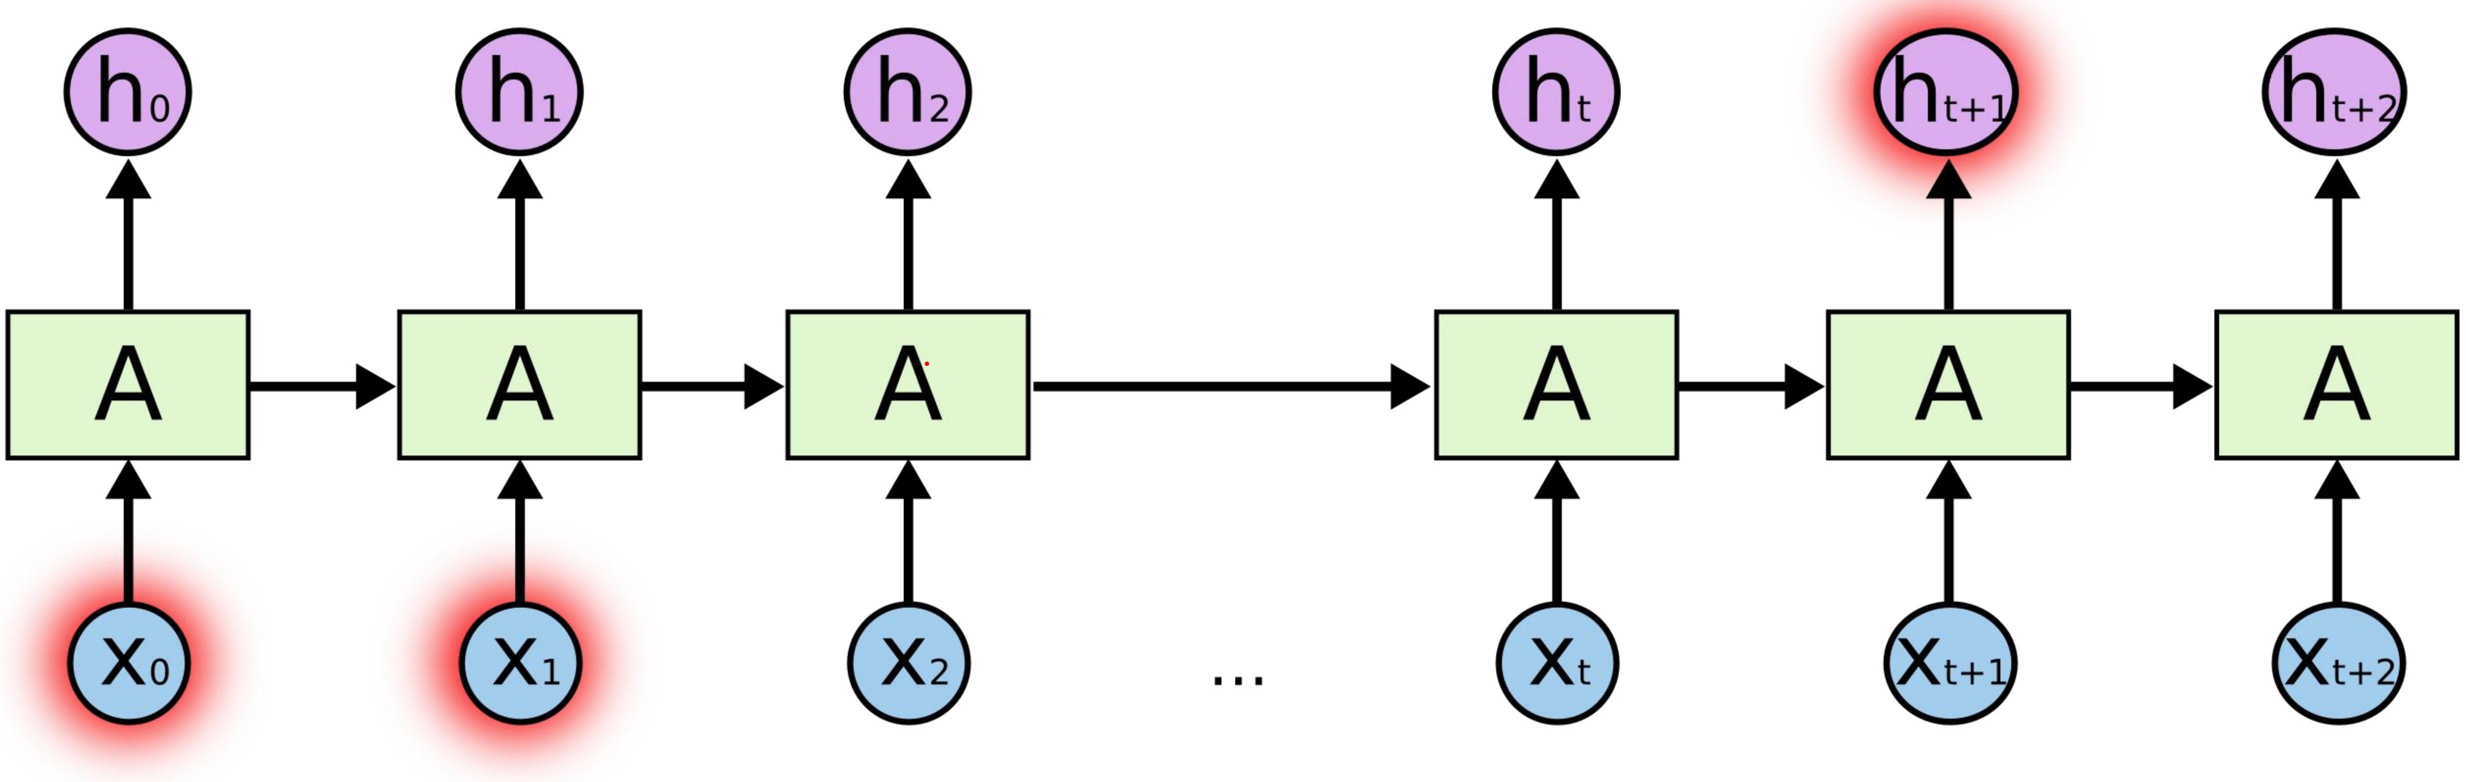

LSTM

- 将“记忆细胞”变得稍微复杂一点点

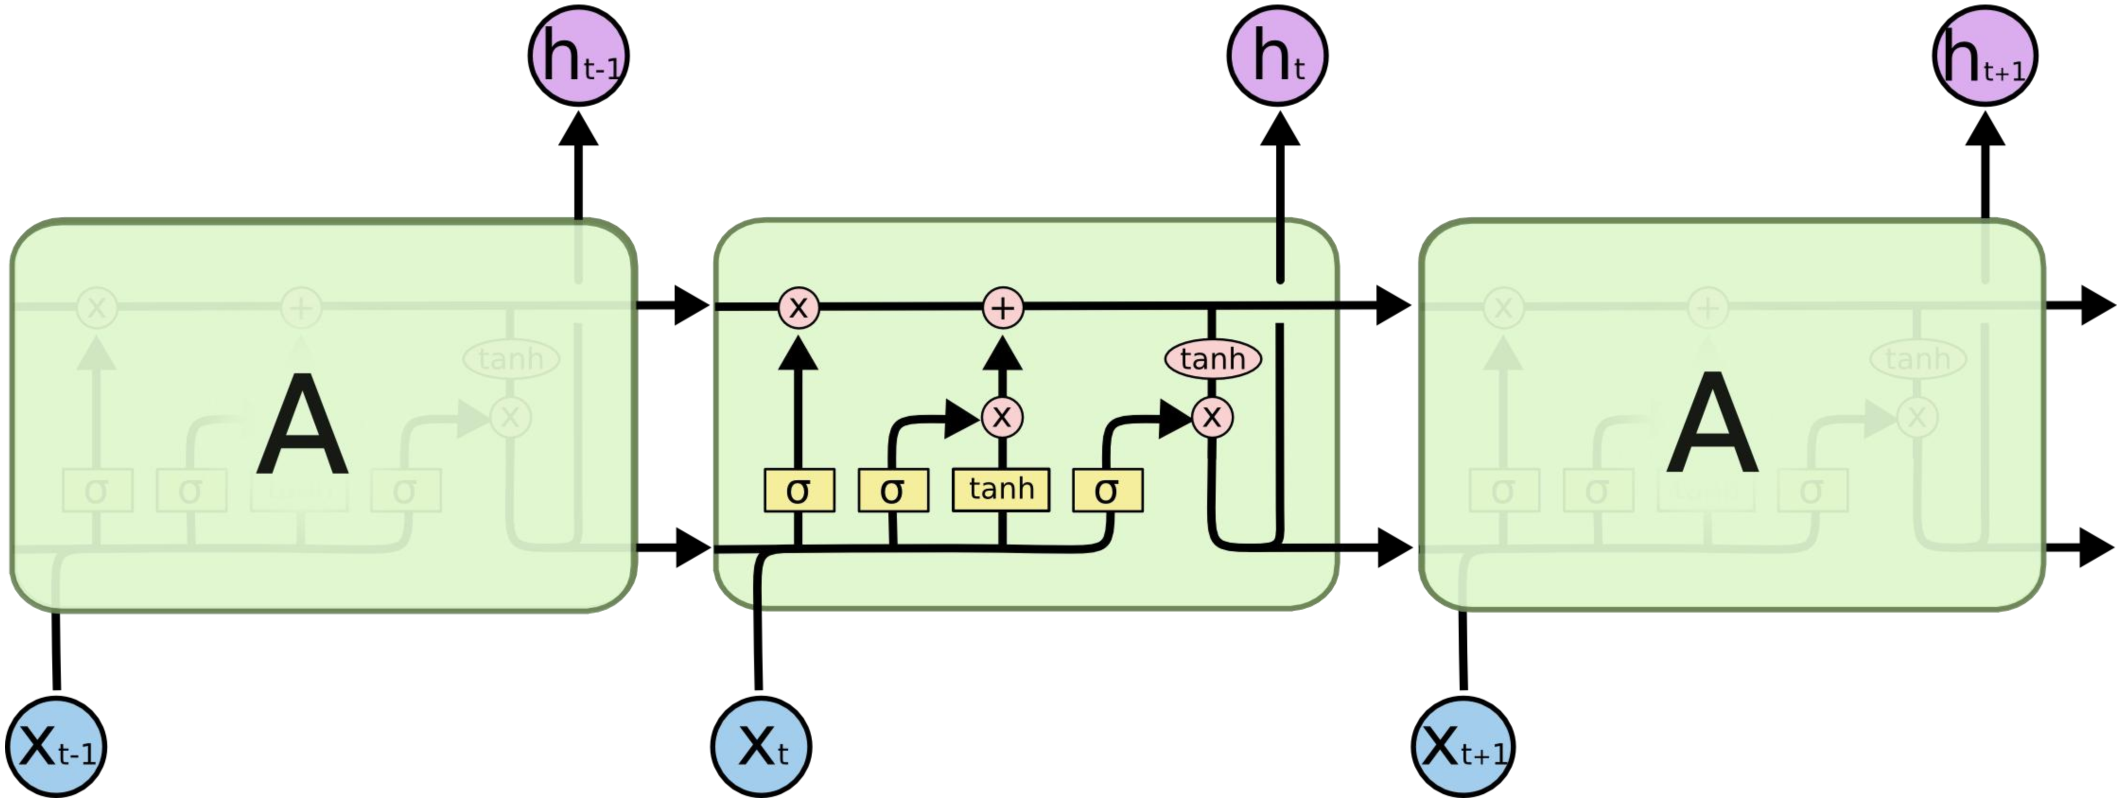

LSTM

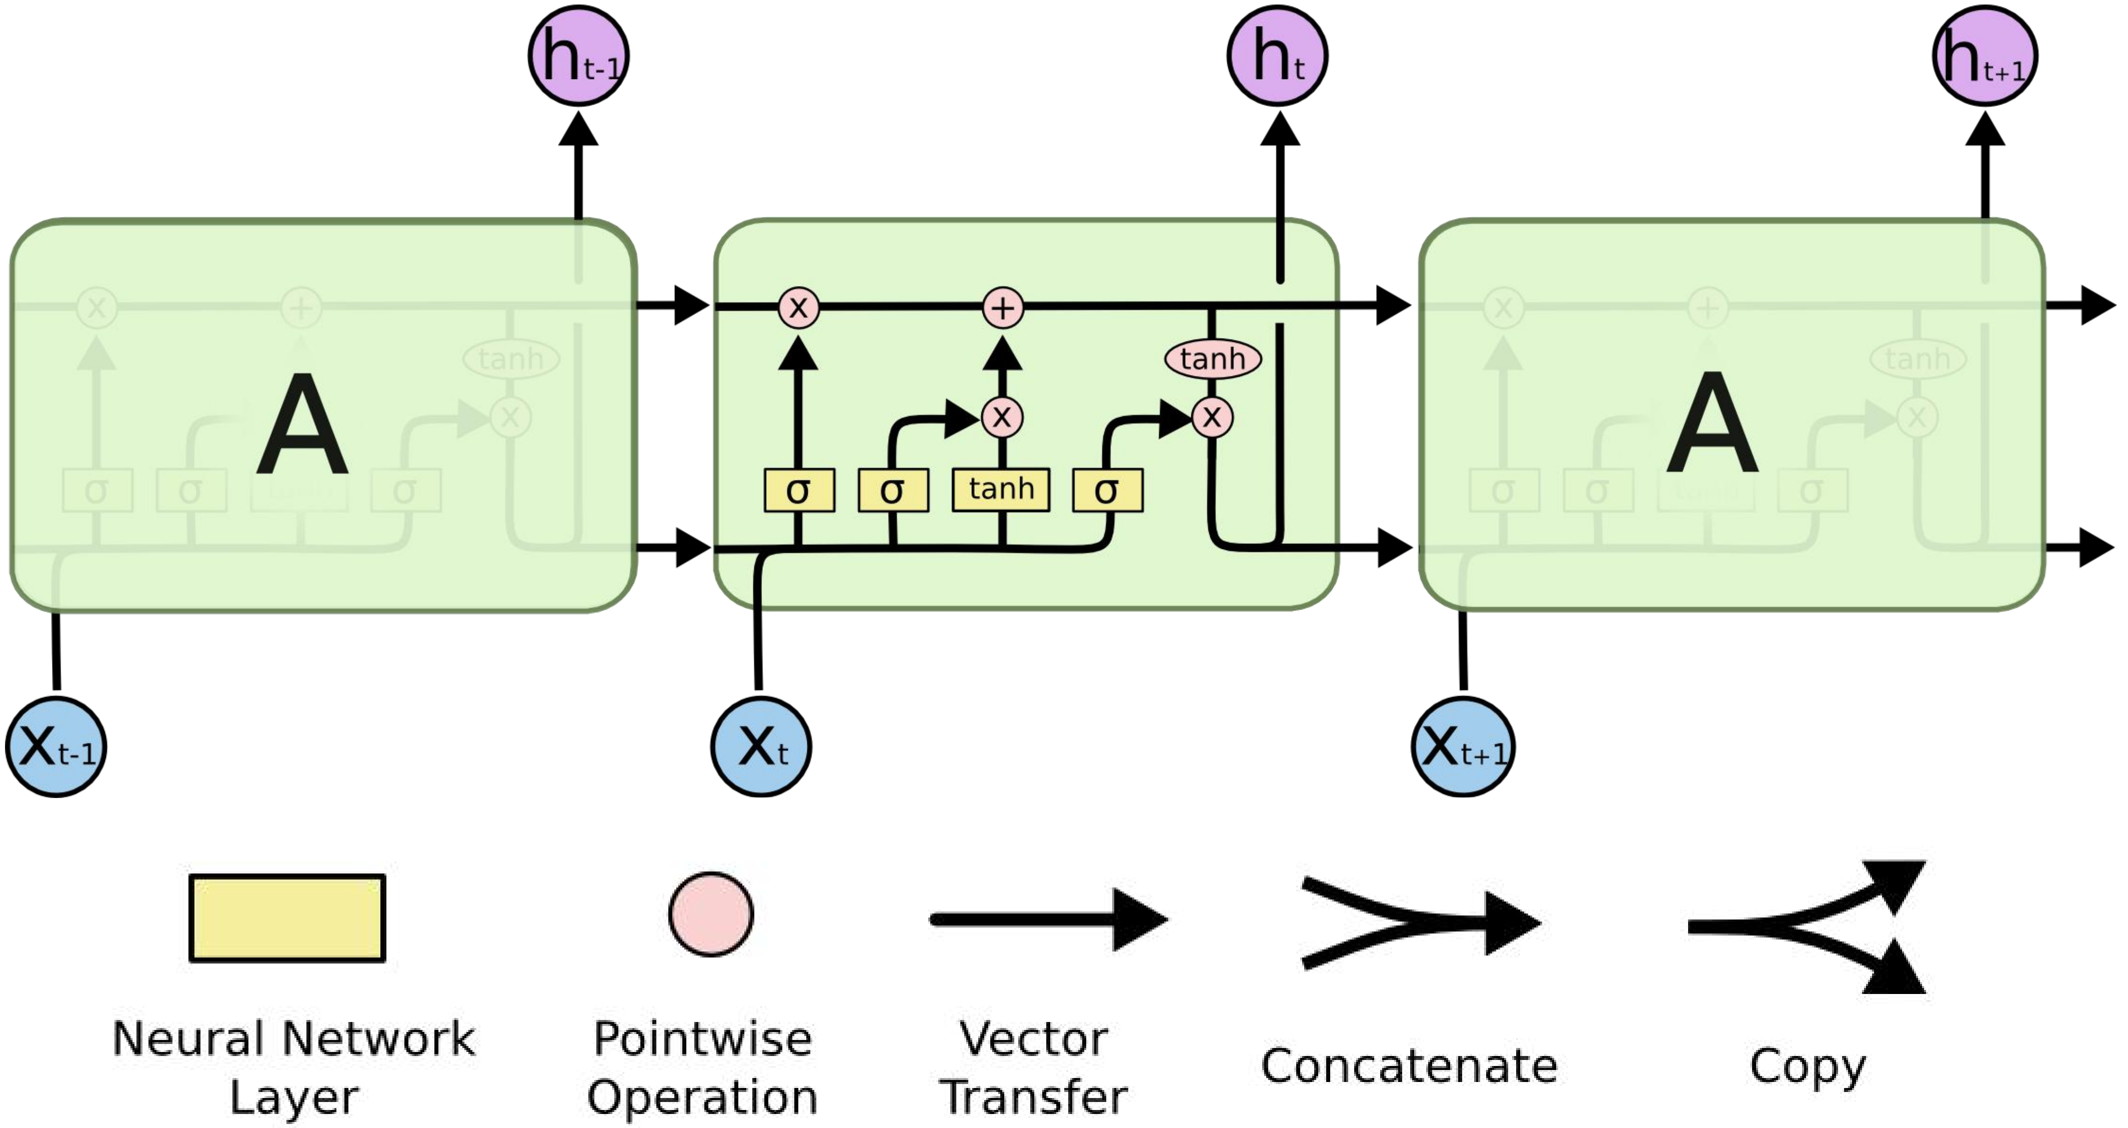

h_{t-1}
h_t
h_{t+1}
A
tanh
tanh
σ
σ
tanh
σ
A
x_{t-1}
x_t
x_{t+1}
Neural Network Layer
Pointwise Operation
Vector Transfer
Concatenate
Copy

LSTM

- LSTM关键：“细胞状态”
  - 细胞状态类似于传送带。直接在整个链上运行，只有一些少量的线性交互。信息在上面流传保持不变很容易。

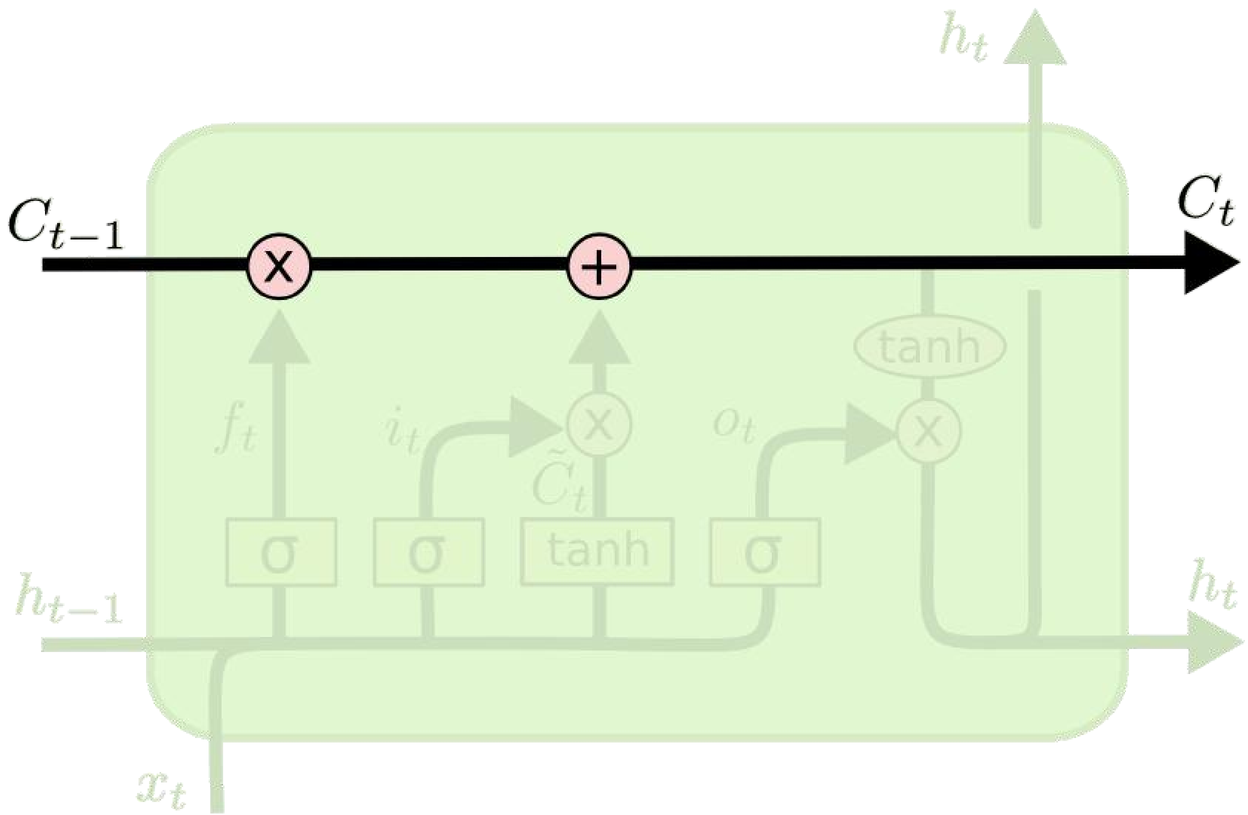

LSTM

- LSTM怎么控制“细胞状态”？
  - LSTM可以通过gates(“门”)结构来去除或者增加“细胞状态”的信息
  - 包含一个sigmoid神经网络层次和一个pointwist乘法操作
  - Sigmoid层输出一个0到1之间的概率值，描述每个部分有多少量可以通过，0表示“不允许任何变量通过”，1表示“运行所有变量通过”
  - LSTM中主要有三个“门”结构来控制“细胞状态”

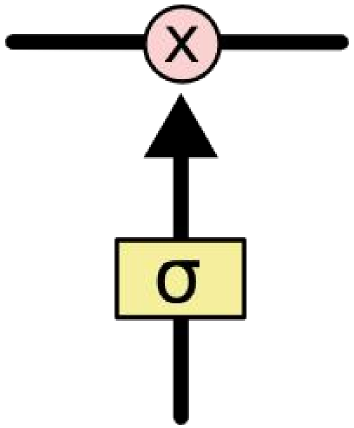

LSTM

- 第一个“门”==>“忘记门”/“遗忘门”：决定从过去的“细胞状态”中丢弃什么信息；比如在语言模型中，细胞状态可能包含了性别信息(“他”或者“她”)，当我们看到新的代名词的时候，可以考虑忘记旧的数据

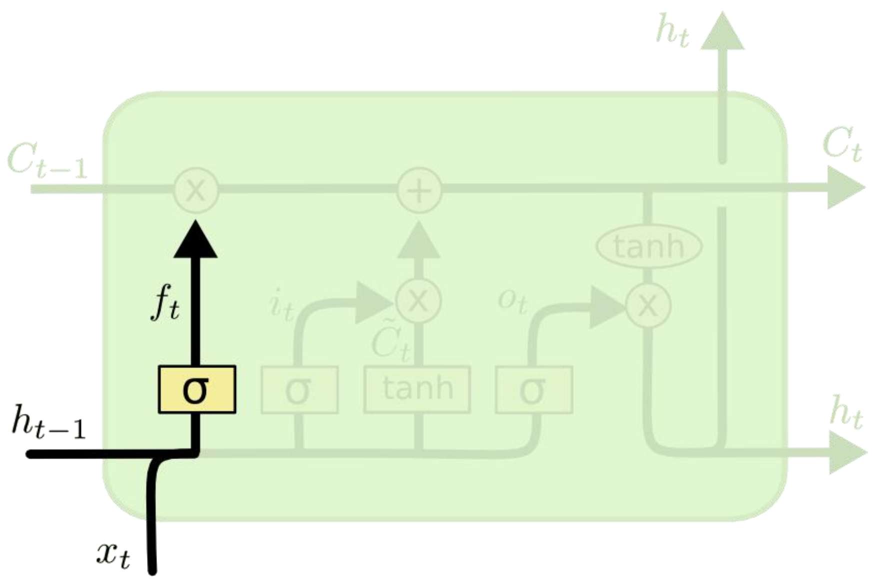

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \ + \ b_f\right)$$

LSTM

- 第二个“门”==>“信息增加门”：决定放什么新信息到“细胞状态”中；
  - Sigmoid层决定什么值需要更新；
  - Tanh层创建一个新的候选向量C_t；
  - 主要是为了状态更新做准备

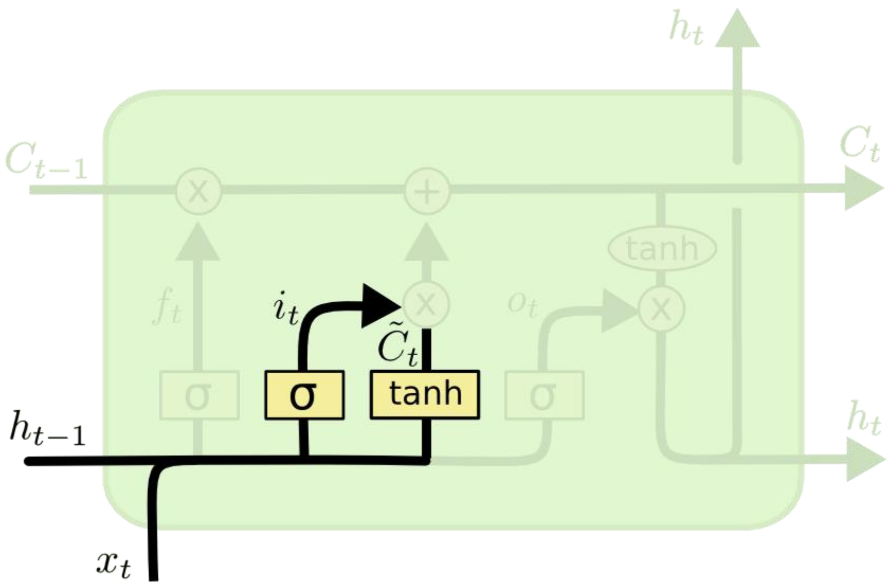

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] + b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

LSTM

- 经过第一个和第二个“门”后，可以确定传递信息的删除和增加，即可以进行“细胞状态”的更新
  - 更新C_{t-1}为C_t;
  - 将旧状态与f_t相乘，丢失掉确定不要的信息；
  - 加上新的候选值i_t*C_t得到最终更新后的“细胞状态”

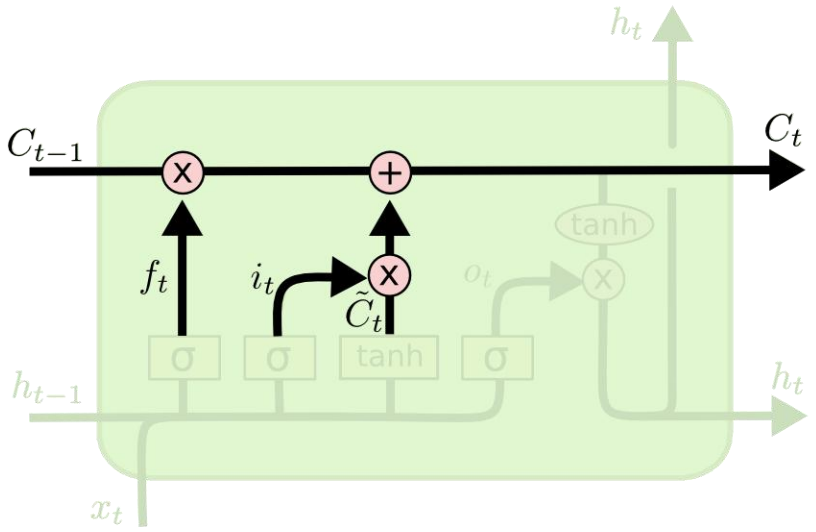

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

LSTM

- 第三个“门”==>基于“细胞状态”得到输出，也就是“输出门”；
  - 首先运行一个sigmoid层来确定细胞状态的那个部分将输出
  - 使用tanh处理细胞状态得到一个-1到1之间的值，再将它和sigmoid门的输出相乘，输出程序确定输出的部分。

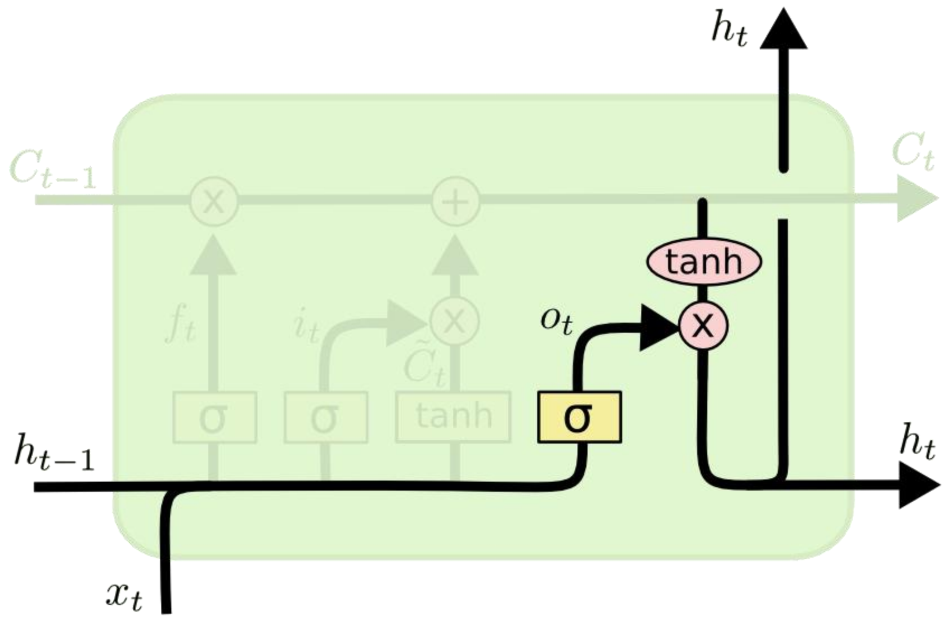

$$o_t = \sigma\left(W_o\ [h_{t-1}, x_t]\ +\ b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

LSTM变种

- 变种1
  - 增加“peephole connections”层
  - 让门层也接受细胞状态的输入

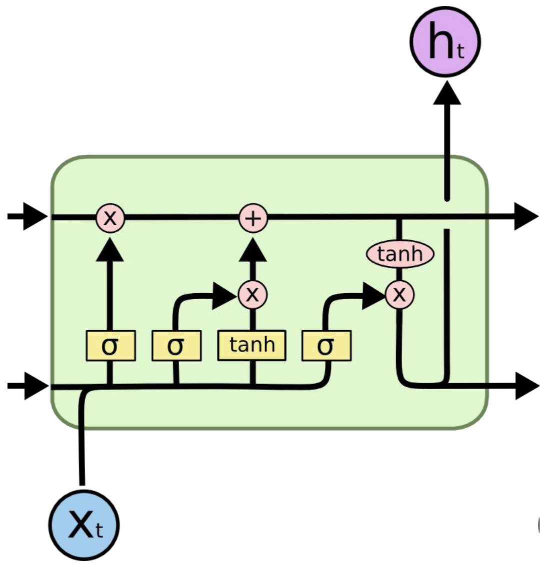

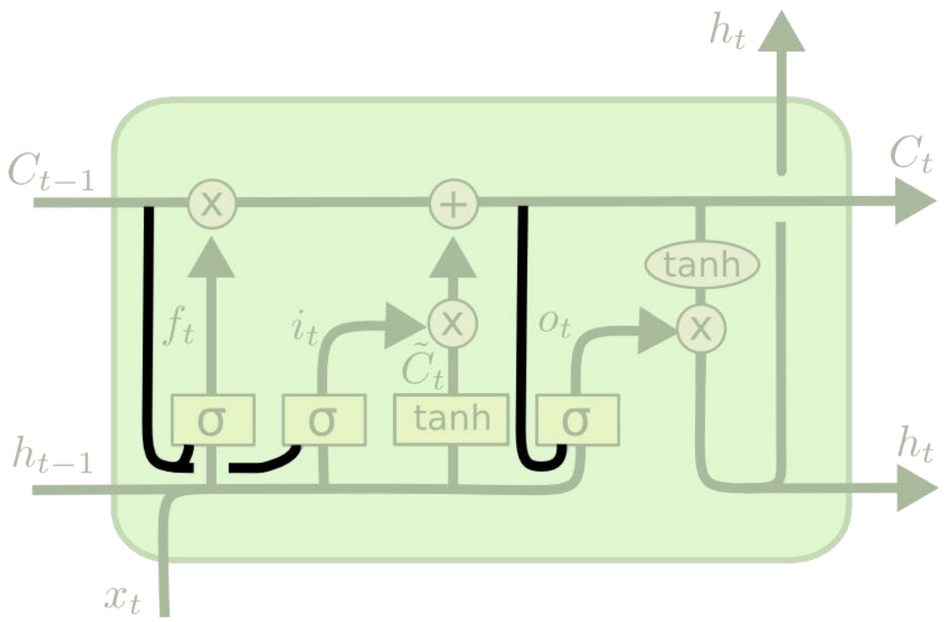

$$f_t = \sigma\left(W_f \cdot [\boldsymbol{C_{t-1}}, h_{t-1}, x_t] + b_f\right)$$
$$i_t = \sigma\left(W_i \cdot [\boldsymbol{C_{t-1}}, h_{t-1}, x_t] + b_i\right)$$
$$o_t = \sigma\left(W_o \cdot [\boldsymbol{C_t}, h_{t-1}, x_t] + b_o\right)$$

LSTM变种

变种2

- 通过耦合忘记门和更新输入门(第一个和第二个门)；也就是不再单独的考虑忘记什么、增加什么信息，而是一起进行考虑。

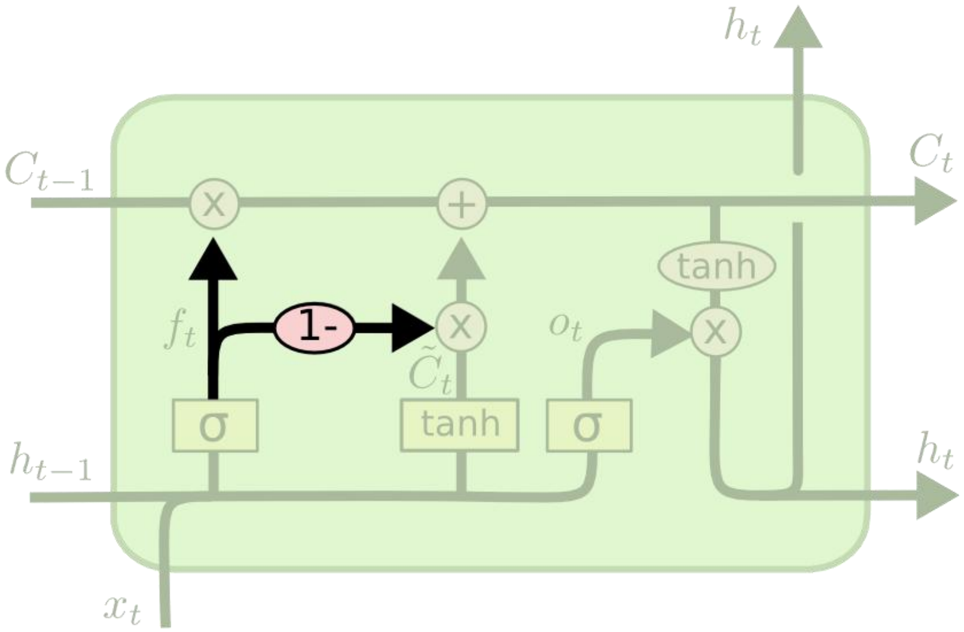

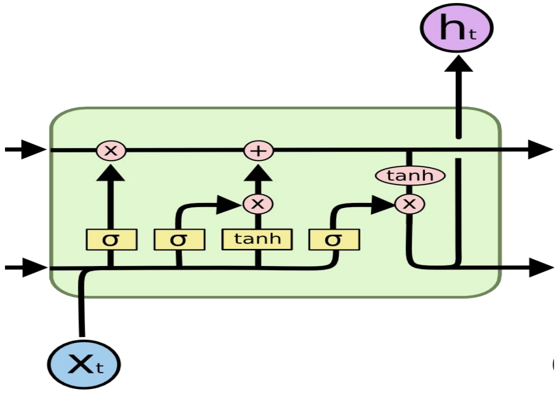

$$C_t = f_t * C_{t-1} + (1 - \boldsymbol{f_t}) * \tilde{C}_t$$

GRU

- Gated Recurrent Unit(GRU)，2014年提出
  - 将忘记门和输出门合并成为一个单一的更新门
  - 同时合并了数据单元状态和隐藏状态(细胞状态和输出状态)
  - 结构比LSTM的结构更加简单

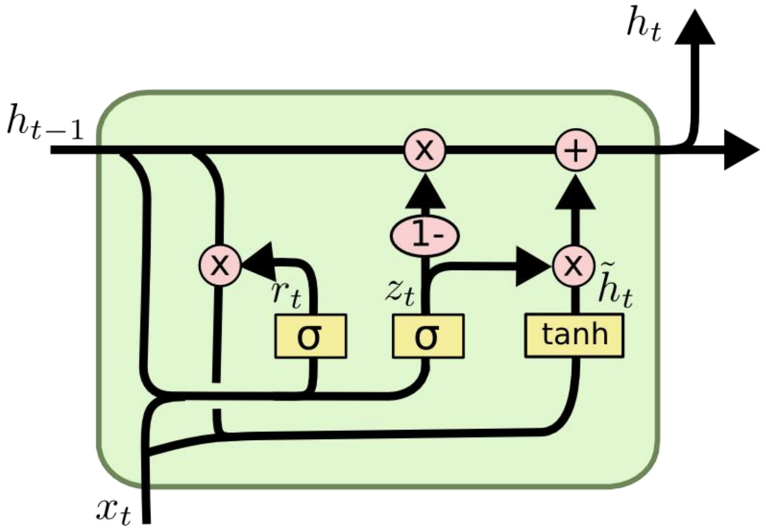

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right)$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right)$$

$$\tilde{h}_t = \tanh\left(W \cdot [r_t * h_{t-1}, x_t]\right)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

THANKS!